

你的理解非常准确，而且你提出了一个**建模逻辑层面的关键问题**：**问题1的变量筛选和问题2的预测建模应该如何划分边界**。这个地方如果处理不好，论文结构会显得“问题1和问题2混在一起”。

先给结论：

多元线性回归模型不应该作为问题1的主体模型，而应该放在问题2中。

问题1中的LASSO可以独立完成变量筛选；问题2再利用问题1筛选出的变量建立血糖预测模型。多元线性回归属于预测模型，而不是变量筛选模型。

下面详细解释。

一、LASSO后的多元线性回归到底是不是“验证”？

严格来说：

不是简单的验证，而是“二次筛选与模型解释”。

容易混淆的是：

- LASSO：变量选择工具
- 多元线性回归：预测模型

二者目的不同。

1. LASSO做什么？

你的问题1目标：

从42个指标中筛选主要变量指标。

数学表达：

已有：

$$Y = \text{血糖}$$

候选变量：

$$X_1, X_2, \dots, X_{40}$$

LASSO：

$$\min \sum (Y_i - \hat{Y}_i)^2 + \lambda \sum |\beta_j|$$

结果：

部分：

$$\beta_j = 0$$

例如：

原始：

40个指标

LASSO：

保留：

$$X_3, X_7, X_{15}, X_{22}, X_{30}$$

那么问题1完成：

这些变量具有较强的血糖解释能力。

2. 那为什么还需要多元线性回归？

因为LASSO有一个缺点：

它更偏向：

“预测贡献”。

但是医学研究还关心：

- 影响方向；
- 影响程度；
- 显著性。

例如：

LASSO告诉你：

保留：

甘油三酯。

但是它没有告诉：

甘油三酯每增加 1mmol/L

血糖增加多少。

多元线性回归可以：

$$\text{BloodGlucose} = \beta_0 + \beta_1 \text{TG} + \beta_2 \text{Age} + \dots$$

得到：

例如：

$$\beta_{\text{TG}} = 0.42$$

解释：

甘油三酯升高1单位，血糖平均增加0.42。

所以：

多元回归不是验证LASSO准确性，而是：

对LASSO筛选出的变量进行统计解释和建立预测关系。

二、那么问题1应该放什么模型？

你的问题1：

结合附件1检测数据，从42个检测指标中筛选出主要变量指标，并详细说明建模主要变量筛选过程及合理性。

核心关键词：

筛选

不是：

预测。

所以推荐：

问题1模型流程

Step 1 数据预处理

删除：

- id
- 日期

得到：

40个指标。

Step 2 单因素统计筛选

目的：

降低噪声。

例如：

连续变量：

$$r(X_i, Y)$$

分类变量：

t检验。

结果：

40 → 15

Step 3 LASSO变量选择

目的：

进一步压缩。

结果：

15 → 5~10

例如：

最终：

变量

年龄

甘油三酯

HDL

尿酸

ALT

白细胞

问题1结束。

输出：

主要变量指标集合。

三、问题2应该放多元线性回归

问题2：

根据体检数据建立血糖值预测模型。

这里目标明确：

输入：

$$X$$

输出：

$$Y = \text{血糖}$$

所以建立：

模型1：多元线性回归（基础模型）

$$Y = \beta_0 + \sum_{i=1}^k \beta_i X_i$$

其中：

X：

问题1筛选出的变量。

模型2：可以进一步优化

考虑医学数据特点：

(1) 岭回归

解决：

变量相关。

例如：

TG和TC。

(2) GAM

解决：

非线性。

例如：

年龄。

最终问题2：


比较：


模型	RMSE	R ²
线性回归		
岭回归		
GAM		

选择最佳预测模型。

四、问题1和问题2的关系应该这样写

这是论文逻辑：





五、一个容易犯的错误

很多论文会这样：

问题1：

LASSO筛变量

↓

多元线性回归

然后说：

“通过回归模型验证变量”。

这个表述不准确。

因为：

问题1没有要求建立模型。

正确说法：

利用LASSO方法完成候选变量筛选，并在后续血糖预测模型中利用筛选变量建立回归模型。

六、针对你的题目，我建议最终四问模型安排

问题	目的	模型
问题1	筛选主要指标	相关分析 + LASSO

问题	目的	模型
问题2	预测血糖值	多元线性回归/GAM/岭回归
问题3	糖尿病风险评估	基于问题2预测血糖+风险分层，或者构造风险模型
问题4	无血糖数据预测	调用问题2模型预测

另外补充一个重点：由于附件1没有糖尿病诊断标签，**问题3实际上不能直接建立 Logistic糖尿病分类模型**。更合理的做法可能是：

预测血糖值 → 根据医学阈值划分风险等级

或者：

血糖异常概率模型

这个问题在后续讨论问题3时需要重新设计。你现在对问题1和问题2边界的理解是正确的。



题目第一问确实要求详细说明建模主要变量的筛选过程及其合理性，所以我决定还是在第一问保留多元回归

你的决定是有一定合理性的，而且从“数学建模竞赛论文”的角度来看，**第一问保留多元回归并不是错误**。不过需要注意：**多元回归在第一问中的定位必须调整**，否则会造成“变量筛选”和“预测建模”两个问题之间的功能重叠。

我建议不要把多元回归作为第一问的预测模型，而是把它定位为：

变量筛选后的统计检验与重要性评价模型。

这样既满足第一问“详细说明筛选过程及合理性”的要求，又不会提前消耗第二问的建模内容。

一、为什么第一问保留多元回归是合理的？

题目要求：

从42个检测指标中筛选出主要变量指标，并详细说明建模主要变量的筛选过程及其合理性。

这里有两个关键词：

1. 筛选
2. 合理性

仅使用：

- Pearson相关
- Spearman相关
- LASSO

只能说明：

这些变量与血糖存在统计关联，或者具有预测贡献。

但是无法很好回答：

为什么这些变量可以作为主要变量？

例如：

LASSO选出了：

- 年龄
- 甘油三酯
- ALT
- 尿酸

但是评委可能会问：

- 年龄为什么重要？
- 甘油三酯影响方向是什么？
- ALT是否独立影响血糖？

这时多元回归就有作用。

二、多元回归在第一问中的正确位置

推荐你的第一问流程：

Step 1：数据预处理

42个指标：

删除：

- id
- 体检日期

剩余：

40个候选指标。

Step 2: 单因素统计筛选

目的：

去除明显无关变量。

连续变量：

Pearson/Spearman：

$$r_i = \text{corr}(X_i, Y)$$

分类变量：

t检验/ χ^2 检验。

筛选：

$$p < 0.05$$

例如：

40 $\rightarrow$ 18

Step 3: LASSO变量压缩

目的：

处理：

- 变量较多；
- 共线性。

模型：

$$\min \left[\sum (y_i - \beta X_i)^2 + \lambda \sum |\beta_i| \right]$$

结果：

18 → 8

Step 4: 多元线性回归验证变量合理性

这里就是你想加入的部分。

建立：

$$Y = \beta_0 + \beta_1 X_1 + \dots + \beta_k X_k$$

其中：

$$Y = \text{血糖}$$

输入：

LASSO筛出的变量。

然后分析：

(1) 回归系数

例如：

$$\beta_{TG} = 0.36$$

说明：

甘油三酯升高，血糖升高。

(2) 显著性检验

检验：

$$H_0 : \beta_i = 0$$

如果：

$$p < 0.05$$

说明：

该变量具有独立贡献。

(3) 多重共线性检验

计算：

VIF：

$$VIF_i = \frac{1}{1 - R_i^2}$$

要求：

$$VIF < 10$$

说明变量之间不存在严重共线。

最后确定：

主要变量。

三、这样第一问和第二问如何区分？

这是关键。

第一问：

重点：

找变量。

多元回归作用：

解释变量贡献。

输出：

例如：

最终主要指标：

$$X = \{\text{年龄}, TG, HDL, \text{尿酸}, ALT\}$$

并说明：

- 相关性；
- 显著性；

- 影响方向。

第二问：

重点：

用变量预测血糖。

这时重新建立预测模型。

例如：

模型A：

多元线性回归：

$$Y = \beta X$$

模型B：

岭回归：

$$Y = \beta X$$

模型C：

GAM：

$$Y = f(X)$$

比较：

- RMSE
- MAE
- R²

选择最佳预测模型。

所以：

虽然第一问和第二问都可能出现“回归”，但目的不同：

	第一问	第二问
目标	筛变量	预测
回归作用	解释、验证	拟合、预测

	第一问	第二问
评价指标	p值、 β 、VIF	RMSE、MAE、 R^2
输出	关键指标	血糖预测模型

四、还有一个更严谨的改进：第一问不要叫“多元线性回归验证”

建议论文中不要写：

使用多元线性回归验证LASSO结果。

因为统计意义不严谨。

建议写：

利用多元线性回归模型对LASSO筛选后的变量进行二次评价，通过回归系数显著性检验和多重共线性分析确定最终主要影响指标。

这个表述更专业。

五、针对你的42项指标，我认为最终第一问模型应该是：

原始42指标

↓

删除ID、日期

↓

变量类型划分

↓

单因素统计分析
(Pearson/Spearman/t检验)

↓

初步筛选

↓

LASSO回归

↓

候选核心变量

↓

多元线性回归

↓

显著性检验+VIF分析

↓

最终主要变量

我认为你的想法是对的：**第一问保留多元回归会让“筛选过程及合理性”更加完整。**但是一定要控制它的角色——它是“变量筛选后的统计解释工具”，而不是第二问意义上的“预测模型”。这样两个问题之间既有联系，又不会重复。



结合数学建模和医学研究两个方面，有哪些可视化的思路呀

你的问题问得很好。对于这个题目（体检指标 → 血糖 → 糖尿病风险），可视化不是简单“画几个图”，而是要服务于三个目的：

- 1. 展示数据特征（数据探索）
- 2. 证明变量筛选过程合理（问题1）
- 3. 解释模型结果（问题2、3、4）

结合**数学建模论文**和**医学研究论文**的习惯，我建议按照建模流程设计可视化。

一、数据探索阶段（问题1前置分析）

1. 样本基本信息分布图

目的：