



今天 14:13

你的意思是：线性模型：
多元线性回归
岭回归

非线性模型：
随机森林这样吗

对，你理解的是这个意思。不过结合你的题目，我建议稍微调整一下，不要把模型堆得太多，而是形成**“统计模型组 + 非线性预测模型组”**的结构。

你的第二问可以设计为：



1. 统计模型部分

(1) 多元线性回归（MLR）

作为基础模型：

$$Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p + \varepsilon$$

作用：

- 建立血糖与体检指标之间的线性关系；

- 给出变量影响方向;
- 提供医学解释。

例如:

你的结果:

$$\beta_{age} = 0.0262$$

可以解释:

年龄增加, 血糖水平呈升高趋势。

(2) 岭回归 (Ridge Regression)

作为线性模型优化:

$$\min \sum (y_i - \hat{y}_i)^2 + \lambda \sum \beta_i^2$$

作用:

解决:

- 指标之间相关性;
- 回归系数不稳定。

例如:

TG、TC、LDL存在相关关系时, 岭回归比普通线性回归更加稳定。

2. 非线性模型部分

(3) 随机森林回归 (Random Forest Regression)

模型:

$$\hat{Y} = \frac{1}{M} \sum_{m=1}^M T_m(X)$$

作用:

捕捉:

- 年龄与血糖的非线性关系;
- 多指标组合效应。

例如：

可能存在：

年龄>50岁后血糖增长更快。

这种关系线性模型难以描述，但随机森林可以学习。

但是，我建议不要加入太多模型

例如：

不要：

- BP神经网络
- XGBoost
- SVR
- LightGBM

全部加入。

原因：

你的数据：

- 42个指标；
- 体检数据；
- 医学解释需求强。

不是典型的大规模机器学习任务。

三个模型已经足够：

模型	角色
多元线性回归	基础解释模型
岭回归	优化线性模型
随机森林	非线性预测模型

3. 最终如何确定最优模型？

例如得到：

模型	RMSE	MAE	R^2
多元线性回归	0.65	0.48	0.52
岭回归	0.61	0.45	0.57
随机森林	0.52	0.38	0.70

那么：

预测任务：

选择：

随机森林回归

但是论文中仍保留：

- 多元线性回归解释变量；
- 岭回归证明线性关系稳定。

4. 一个小调整建议

因为你第一问已经用了：

- LASSO；
- 多元线性回归；

所以第二问如果再写：

“多元线性回归模型”

容易和第一问重复。

建议第二问标题：

4.2.1 基于线性回归的血糖预测模型

下面包含：

- 普通线性回归；
- 岭回归。

然后：

4.2.2 基于随机森林的非线性血糖预测模型

这样论文逻辑会更清晰：

第一问：统计筛选变量

第二问：比较不同预测模型

第三问：风险分类评价

整体结构是合理的。你现在这个方向已经比较接近医学统计类数学建模论文的标准框架。

